



基于对抗学习的电子鼻传感器漂移补偿算法*

陶 洋, 黎春燕, 梁志芳, 杨皓诚
(重庆邮电大学 通信与信息工程学院, 重庆 400065)

摘 要: 电子鼻是一种生物嗅觉系统, 主要由气体传感器阵列和模式识别组成, 并已应用在生活的许多领域。但是在电子鼻实际应用中传感器易发生漂移, 致使电子鼻性能下降。本文提出一种基于对抗学习估计域不变原型方法用于补偿传感器漂移。该算法包含一个由神经网络构成的特征提取器和分类器, 并利用条件熵度量无标记目标域特征和估计原型(每一类的表示)的相似度。为使目标域特征更具有区分性, 训练分类器最大化熵, 训练特征提取器最小化熵。最后, 实验结果表明: 该算法能够有效减少电子鼻传感器漂移。
关键词: 漂移补偿; 域自适应; 电子鼻; 对抗学习
中图分类号: TP 212 **文献标识码:** A **文章编号:** 1000-9787(2022)06-0109-05

Electronic nose sensor drift compensation algorithm
based on adversarial learning*

TAO Yang, LI Chunyan, LIANG Zhifang, YANG Haocheng
(School of Communication and Information Engineering, Chongqing University of Posts and
Telecommunications, Chongqing 400065, China)

Abstract: Electronic nose (E-nose) is a bionic olfactory system, which is mainly composed of gas sensor array and pattern recognition, and has been applied to many fields in our life. However, sensor drift is easy to occur in realistic application scenario of E-nose, which makes a decrease in performance of E-nose. Aiming at this problem, a method, namely estimate domain-invariant prototypes via adversarial learning (ALDIP), is put forward for sensor drift compensation. The basic model for the algorithm includes a feature extractor and classifier composed of neural networks, and uses the conditional entropy to calculate the similarity between the unlabeled target domain features and the estimated prototypes (representatives of each class). In order to make features of the target domain have more discrimination, train the classifier to maximize entropy and minimizes it with respect to the feature extractor. Finally, experiments show that the algorithm can effectively reduce drift of E-nose sensor.
Keywords: drift compensation; domain adaption; electronic nose (E-nose); adversarial learning

0 引 言

电子鼻是一种检测复杂性气味的仪器, 又称为机器嗅觉系统, 主要由气体传感器阵列和相应的模式识别算法组成。它在食品安全^[1]、空气质量检测^[2]、医学^[3]等领域有着广泛的应用。但电子鼻传感器的灵敏度会随着环境、自身老化和“中毒”等原因发生变化, 故传感器的输出响应也随之改变, 即传感器产生漂移。传感器漂移使电子鼻性能下降, 寿命降低, 极大限制了电子鼻在实际生活中的应用。因此, 解决传感器漂移能够延长电子鼻使用寿命, 同时也是近年来针对电子鼻的研究热点。

目前, 已有许多学者针对电子鼻传感器漂移提出了一系列方法, 主要包括信号预处理^[4]、成分校正法^[5,6]、分类器集成法^[7]、域自适应法^[8,9]。信号预处理独立校正每只传感器响应信号, 故该方法易于实现、时效性高, 但无法处理数只传感器之间复杂的漂移。成分校正法试图利用实验环境下参考气体的漂移方向移除测试样本的漂移成分, 但漂移方向的准确性依然值得研究。分类器集成法需利用大量标记样本。域自适应是近年来在电子鼻漂移补偿中应用较为广泛的方法, 本文也将从域自适应角度继续研究漂移补偿算法。Zhang L 等人提出域自适应极限学习机 (domain

收稿日期: 2020-05-21
* 基金项目: 重庆市教育委员会科学技术研究项目 (KJQN201800617)

adaptive extreme learning machine, DAELM) 方法用于补偿传感器漂移^[8]。Liang Z 等人^[9]提出一种方法从特征和分类器决策层解决电子鼻传感器漂移。综上所述,这些漂移补偿方法均属于半监督域自适应方法,并抑制了传感器的漂移,但这些方法利用较多的目标域标记样本。

本文受对抗学习和半监督域自适应的启发,提出一种基于对抗学习估计域不变原型(estimate domain-invariant prototypes via adversarial learning, ALDIP) 的漂移补偿方法。将对抗学习加入半监督域自适应学习过程中,同时利用更少的目标域标记样本研究传感器漂移补偿算法。该方法的主要目的是最小化估计原型与目标域未标记样本之间的距离,从而提取目标域可区分性特征。实验表明,本文所提出的方法能够有效地对传感器漂移进行补偿。

1 基于对抗学习估计域不变原型

1.1 问题定义

传感器漂移使漂移前后收集数据的统计分布发生改变,致使模式识别精度降低。在半监督域自适应中,源域样本为 $D^s = \{(\mathbf{x}^i, y^i)\}_{i=1}^{m^s}$, 少量目标域标记样本为 $D^d = \{(\mathbf{x}^i, y^i)\}_{i=1}^{m^d}$, 以及目标域无标记样本 $D^u = \{(\mathbf{x}^i)\}_{i=1}^{m^u}$ 。最后,利用 D^s, D^d, D^u 训练模型,并在 D^u 上进行验证。

1.2 模型总体结构框架

受文献[10]的启发,本文提出的方法主要利用神经网络构建一个特征提取器和余弦相似度分类器。整个网络结构如图 1 所示。




图 1 基于对抗学习域不变原型的网络框架

余弦相似度分类器相当于对特征提取器 F 提取的特征 \mathbf{z} 和分类器 C 的权重向量 $\mathbf{W}=[\mathbf{w}_1, \mathbf{w}_2, \cdots, \mathbf{w}_k]$ 分别进行 L2 范数归一化,即样本的类别分数为 $s=\cos(\mathbf{z}^T, \mathbf{W})=\bar{\mathbf{z}}^T \bar{\mathbf{W}}$, 其中 $\bar{\mathbf{z}}=\mathbf{z} / \|\mathbf{z}\|, \bar{\mathbf{W}}=\mathbf{W} / \|\mathbf{W}\|$, 是 \mathbf{z} 和 \mathbf{W} 经过 L2 范数归一化的结果。再将类别分数经过 SoftMax 函数,则样本的预测概率为 $p(\mathbf{x})=\sigma(\bar{\mathbf{z}}^T \mathbf{W})$, 其中 $\sigma(\cdot)$ 表示 SoftMax 函数。为增加目标域分类准确性,利用源域和目标域标记样本训练分类器,同时将分类器权重向量视为类别估计原型^[10],并利用熵度量估计原型与目标域未标记样本的距离。首先,将权重向量移向目标域且最大化目标域未标记样本的熵;其次,更新特征提取器最小化目标域未标记样本的熵,从而使目标域样本更好地聚集在原型周围。上述过程可视为权重向量与特征提取器的极大极小化过程(对

抗学习过程),该过程可利用梯度反转实现。

1.3 训练过程

在整个训练过程中,首先利用特征提取器 F 和余弦相似度分类器 C 训练源域和目标域标记样本,并选用交叉熵作为损失函数。特征提取器表示为利用网络参数 θ_F 学习一个函数 f_g ,分类器表示为利用网络参数 θ_C 学习一个函数 f_c ,其中, θ_C 为分类器权重向量 $\mathbf{W}=[\mathbf{w}_1, \mathbf{w}_2, \cdots, \mathbf{w}_k]$ 的集合。最后,利用标记样本获得的分类器经验损失为 ℓ

ℓ(𝑥,𝑦) ∈ 𝐷^𝑠, 𝐷^𝑑 = ∑_{𝑖=1}^{𝑚^𝑠+𝑚^𝑑} 𝐿(𝑝(𝑥_𝑖), 𝑦_𝑖) (1)

式中 $L(p(x_i)) = -\sum_{k=1}^K 1(y_i=k) \log p(y=k|x_i)$ 为交叉熵损失函数, K 为类别数量, $p(\mathbf{x})=f_c(f_g(\mathbf{x}))$ 为预测的类别概率, $p(y=k|x_i)$ 为第 k 维预测概率。随着分类器损失逐渐减小,特征提取器可学到源域和少量目标域标记样本的可区分性特征,但无法学到整个目标域的可区分性特征,故提出利用最大最小化熵对目标域未标记样本进行训练。

假设对于每种类别都存在一个域不变估计原型,并视该原型为两个域之间的代表点,但估计原型更适于源域分布,因为在分类器训练过程中源域标签信息更多。为使估计原型具有域不变特性,将原型 \mathbf{w}_i 向目标域特征移动以估计原型的位置,故利用熵度量 \mathbf{W} 与无标记目标域特征之间的相似度,熵的计算公式如下

H = -E_{(x,y) ∈ D^u} ∑_{k=1}^K p(y=k|x) log p(y=k|x) = -E_{(x,y) ∈ D^u} ∑_{k=1}^K f_c(f_g(x))_k log f_c(f_g(x))_k (2)

式中 K 为类别数量, $p(y=k|x)$ 为样本 \mathbf{x} 预测为类别 k 的概率。熵越大则表明估计原型 \mathbf{w}_i 与所有目标域特征越相似,故最大化熵以估计域不变原型。为获得目标域样本可区分性特征,将目标域未标记样本围绕估计原型聚类,故最小化特征提取器 F 以减小目标域未标记样本的熵,即每个目标域样本应分配给唯一的估计原型。因此,重复进行熵最大化和最小化过程能够学到更具有区分性的特征。整个熵的最大最小化过程如图 2 所示。




图 2 熵最大最小化过程

总的来说,该方法可形式化为 C 和 F 之间的对抗学习,训练分类器 C 最大化熵,训练特征提取器 F 以最小化

熵。整个对抗学习的目标函数为

$$\hat{\theta}_F = \arg \min_{\theta_F} \ell + \gamma H$$
$$\hat{\theta}_C = \arg \min_{\theta_C} \ell - \gamma H$$

(3)

式中 γ 为超参数,用于控制最大最小化熵训练和分类损失之间的平衡。在一个包含有源域和目标域小批量数据中,该目标函数可形式化为最大最小化迭代训练。小批量是指将两个域的所有样本划分成几个批次,并以每个批次更新神经网络的参数,从而降低计算复杂度。为简化训练过程,利用梯度反转层^[11]使 C 和 F 之间的梯度相对于 H 反转,其中,梯度反转层可利用一次前向和后向传播实现最大最小化训练。

2 实验与结果分析

2.1 传感器基准数据集

本文利用一组公开数据集完成实验,它被许多学者用于电子鼻漂移补偿算法研究。该数据是长达3年的电子鼻传感器基准数据集,由来自加州大学(University of California, San Diego,UCSD)的 Vergara 等人^[7]采集所得。电子鼻是由16只MOS传感器组成的传感器阵列,其中每只传感器提取样本的8个特征,故每个样本共有128(16×8)维特征。最后,利用电子鼻对不同浓度的6种气体(丙酮,乙醛,乙醇,乙烯,氨和甲苯)进行测量,在整个36个月中共收集了13910个样本,并按时间顺序将其分为10批数据。其中,第10批数据是电子鼻关闭电源5个月所采集的数据,而在电子鼻关闭电源的5个月中,传感器将遭受到严重的污染,且这些污染不可避免,因此当电子鼻再次工作时,电子鼻传感器阵列无法恢复到正常的工作温度,故采集的数据将发生比平常更严重的漂移。表1为所有批次收集的时间以及每个批次每种气体的数量。另外,更多关于论文采用的传感器基准数据集信息可见文献^[7]。

表1 基准传感器漂移数据集

批次号	月数	丙酮	乙醛	乙醇	乙烯	氨	甲苯	总计
1	1,2	90	98	83	30	70	74	445
2	3,4,8,9,10	164	334	100	109	532	5	1244
3	11~13	365	490	216	240	275	0	1586
4	14,15	64	43	12	30	12	0	161
5	16	28	40	20	46	63	0	197
6	17~20	514	574	110	29	606	467	2300
7	21	649	662	360	744	630	568	3613
8	22,23	30	30	40	33	143	18	294
9	24,30	61	55	100	75	78	101	470
10	36	600	600	600	600	600	600	3600

为更直观地观察所有批次数据分布差异,图3为原始数据的二维主成分散点图。从图3中可观察到传感器漂移使各批次的2维主成分子空间数据分布不一致。因此,若

将批次1视为源域用于建立模型,在目标域批次 $b(b=2,3,\cdots,10)$ 上测试,模式识别准确性会产生较大的偏差。因为在机器学习中,通常假设训练集和测试集应保持相同或相似的概率分布,而传感器漂移使测试集和训练集的分布不再满足机器学习的假设,故可考虑减小域间分布差异提高模式识别的准确率。

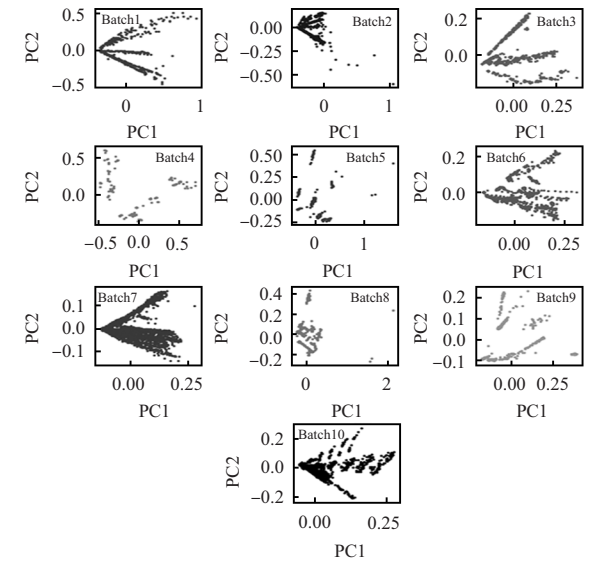


图3 10批数据二维特征(PC1,PC2)散点图

2.2 结果与讨论

对电子鼻传感器基准数据集进行两种实验设置,并将两种实验设置下的结果与一些漂移补偿方法进行对比,包括常用的特征提取方法,主成分分析(principal component analysis,PCA)法^[5]和线性判别分析(linear discriminant analysis,LDA)法^[12],集成分类器法SVM-COMGFK和SVM-RBF,以及近年的半监督域自适应方法,域自适应极限学习机(DAELM-S)^[8]。由于神经网络初始权重的不确定性,故本次实验实现ALDIP共10次,并取实验10次最优结果的平均值作为本实验的结果。在实验过程中,等式(3)中的平衡参数 γ 为0.1,并利用常见的KS算法选取目标域标记样本。

设置1:将批次1作为源域用于模型训练,其余批次 $b(b=2,3,\cdots,10)$ 作为目标域用于模型测试。

设置2:将批次 $b(b=1,2,\cdots,9)$ 作为源域用于模型训练,批次 $b+1$ 作为目标域用于模型测试。

在实验设置1下,表2给出了ALDIP在最佳实验结果下的小批量设置,表3给出了ALDIP与其他漂移补偿算法的识别精度。从表3可知ALDIP平均精度结果最佳,虽然平均精度只比DAELM-S高出0.91%,但从表格的第一列可知ALDIP比DAELM-S少利用10个目标域标记样本。从总的10批数据来看,2,4,5,6,10批次数据的识别精度均比DAELM-S高,尤其第10批数据,ALDIP的识别精度比

DAELM-S 高出 15.17%,由 2.1 节可知,第 10 批数据漂移最严重,故这也证明了该方法对漂移的补偿作用。最后还给出了实验设置 1 下 ALDIP 方法在包含 0,5,10,15,20,25 个目标域标记样本下每批次的识别精度图,并与 DAELM-S 在该环境下的识别精度进行对比,如图 4 所示。从图 4 中可看出随着目标域标记样本的增加,ALDIP 方法的识别精度逐渐增加,且在相同的目标域样本下,大多数批次的识别效果优于 DAELM-S。因此,该模型能够有效补偿传感器漂移。另外 ALDIP 比次之的 DAELM-S 效果更佳的一个原因是 ALDIP 利用了对抗学习使提取的源域和目标域特征具有域不变特性,并且利用余弦相似度分类器可使类内更紧密,而 DAELM-S 利用极限学习机只考虑了分类决策层的自适应。

表 2 实验设置 1 下获得最高精度时小批量参数设置										
批次(b)	2	3	4	5	6	7	8	9	10	
小批量大小	12	12	16	32	32	12	12	32	14	

表 3 实验设置 1 下 ALDIP 以及对比算法的识别精度										
方法	批次(b)									
	2	3	4	5	6	7	8	9	10	平均值
PCA-SVM	82.40	84.80	80.12	75.13	73.57	56.16	48.64	67.45	49.14	68.60
LDA-SVM	47.27	57.76	50.93	62.44	41.48	37.42	68.37	52.34	31.17	49.91
SVM-RBF	74.36	61.03	50.93	18.27	28.26	28.81	20.07	34.26	34.47	38.94
SVMCOMGFK	74.47	70.15	59.78	75.09	73.99	54.59	55.88	70.23	41.85	64.00
DAELM-S(30)	87.98	95.74	85.16	95.99	94.14	83.21	86.90	100	53.62	87.00
ALDIP(20)	89.62	91.69	87.94	100	95.45	76.05	82.81	98.84	68.79	87.91

注:表格内加粗字体表示每批次所有方法中的最高识别精度

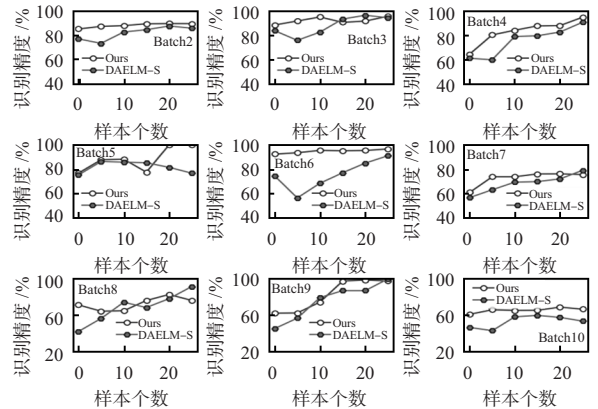


图 4 不同数量目标域标记样本下每个批次的识别精度
在实验设置 2 下,批次 b 视为源域,批次 $b+1$ 视为目标域,若将批次 $b \rightarrow b+1$ 视为一个任务,则共有 9 个任务。表 4 给出了在实验设置 2 下每个任务获得最佳实验结果的小批量大小参数设置。表 5 给出 ALDIP 方法与所有比较的漂移补偿方法对 9 个任务的识别精度结果。从表 5 中可看出 ALDIP 方法的识别精度依然是最高的。虽然仅比与它次之的 DAELM-S 方法高出 0.45%,但该方法依然利用了更少的目标域标记样本。对于现实场景来讲,从目标域获取更多的标记样本将耗费大量人力且不易获取,故这证

明了该方法的有效性。总的来说,无论从实验设置 1 还是实验设置 2,都能够说明 ALDIP 方法对传感器漂移的补偿作用。

表 4 实验设置 2 下获得最高精度时小批量参数设置										
批次($b \rightarrow b+1$)	1 \rightarrow 2	2 \rightarrow 3	3 \rightarrow 4	4 \rightarrow 5	5 \rightarrow 6	6 \rightarrow 7	7 \rightarrow 8	8 \rightarrow 9	9 \rightarrow 10	
小批量大小	12	32	16	32	14	64	14	64	64	

方法	批次($b \rightarrow b+1$)									
	1 \rightarrow 2	2 \rightarrow 3	3 \rightarrow 4	4 \rightarrow 5	5 \rightarrow 6	6 \rightarrow 7	7 \rightarrow 8	8 \rightarrow 9	9 \rightarrow 10	平均值
PCA-SVM	82.40	98.87	83.23	72.59	36.70	74.98	58.16	84.04	30.61	69.06
LDA-SVM	47.27	46.72	70.81	85.28	48.87	75.15	77.21	62.77	30.25	60.48
SVM-RBF	74.36	87.83	90.06	56.35	42.52	83.53	91.84	62.98	22.64	68.01
SVMCOMGFK	74.47	73.75	78.51	64.26	69.97	77.69	82.69	85.53	17.76	69.40
DAELM-S(30)	87.98	96.58	89.75	99.04	84.43	91.75	89.83	100	58.44	88.64
ALDIP(20)	89.62	94.83	100	99.44	80.13	81.55	95.62	100	60.6	89.09

注:表格内加粗字体表示对于每个任务所有方法中的最高识别精度

3 结 论

为了补偿传感器的漂移,本文提出一种基于对抗学习估计域不变原型的算法。该方法的特点为:1)利用熵的最大最小化过程达到源域与目标域之间的自适应;2)在网络结构中,为了达到对抗的目的,在特征提取器和分类器之间加入梯度反转层;3)该模型不仅能够学习到域不变特征,而且能够学习到域不变原型。最后,为了验证提出方法的有效性,在加州大学的电子鼻基准数据集上进行实验,并证明了该方法比其他漂移补偿方法识别率更高。

参考文献:

[1] HE J,XU L,WANG P,et al. A high precise E-nose for daily indoor air quality monitoring in living environment[J]. Integration, 2017,58:286—294.

[2] 贾文坤,李孟楠,王亚雷,等. 电子鼻技术在果蔬检测中的应用[J]. 食品安全质量检测学报,2016,2(2):410—418.

[3] YAN K,ZHANG D. Feature selection and analysis on correlated gas sensor data with recursive feature elimination[J]. Sensors and Actuators B:Chemical,2015,212:353—363.

[4] MARCO S,GUTIERREZ-GALVEZ A. Signal and data processing for machine olfaction and chemical sensing: A review[J]. IEEE Sensors Journal,2012,12(11):3189—3214.

[5] ARTURSSON T,EKLOV T,LUNDSTROM I,et al. Drift correction for gas sensors using multivariate methods[J]. Journal of Chemometrics,2000,14(5—6):711—723.

[6] FENG J,TIAN F,JIA P,et al. Improving the performance of electronic nose for wound infection detection using orthogonal signal correction and particle swarm optimization[J]. Sensor Review, 2014,34(4):389—395.

[7] VERGARA A,SEMBU S,AYHAN T,et al. Chemical gas sensor drift compensation using classifier ensembles[J]. Sensors and Actuators B:Chemical,2012,166(1):320—329.

[8] ZHANG L,ZHANG D. Domain adaptation extreme learning machines for drift compensation in E-nose systems[J]. IEEE

Transactions on Instrumentation and Measurement,2015,64(7):1790—1801.

[9] LIANG Z,TIAN F,ZHANG C,et al. A correlated information removing based interference suppression technique in electronic nose for detection of bacteria[J]. Analytica Chimica Acta,2017,986:145—152.

[10] TZENG E,HOFFMAN J,SAENKO K,et al. Adversarial discriminative domain adaptation[C]//IEEE Conf,2017:96—110.

[11] GIDARIS S,KOMODAKIS N. Dynamic few-shot visual learning without forgetting[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, USA: IEEE, 2018: 4367—4375.

[12] YE J,JANARDAN R,LI Q. Two-dimensional linear discriminant analysis [C] // Advances in Neural Information Processing Systems, Cambridge: MIT Press,2005:1569—1576.

作者简介:
陶洋(1964—),男,教授,博士后,主要研究领域为计算机通信和电子鼻。

(上接第105页)

[5] 陶有俊,赵友男,姜宇帅,等. 低阶烟煤煤岩组分分解离特性及强化重力分选研究[J]. 中国矿业大学学报,2020,49(1):184—189,197.

[6] 宋栓军,陈凯凯,张华威. 基于 APSO 算法的双容水箱 PID 参数优化仿真[J]. 计算机仿真,2018,35(8):261—265.

[7] 汤斌斌,陈敏芳,熊伟丽,等. 一种模糊自适应 PID 控制在溶解氧中的应用[J]. 传感器与微系统,2013,32(7):144—147. TANG Binbin, CHEN Minfang, XIONG Weili, et al. Application of a kind of fuzzy adaptive PID control in DO[J]. Transducer and Microsystem Technologies,2013,32(7):144—147.

[8] 蔡改贫,刘鑫,许琴. 离心选矿系统模糊解耦控制器设计[J]. 河南理工大学学报(自然科学版),2019,38(3):104—110.

[9] 程宗政,施一萍,刘瑾,等. 基于天牛须蜂群 PID 算法的闪蒸罐压力控制[J]. 传感器与微系统,2021,40(9):108—110,113. CHENG Zongzheng, SHI Yiping, LIU Jin, et al. Pressure control of flash tank based on PID algorithm of ABC improved by BAS[J]. Transducer and Microsystem Technologies,2021,40(9):108—110,113.

[10] 朱远帆,杨海仕,俞永伟,等. 模糊 PID 算法在婴儿培养箱解耦控制中的应用[J]. 传感器与微系统,2021,40(7):156—160. ZHU Yuanfan, YANG Haishi, YU Yongwei, et al. Application of fuzzy PID algorithm in decoupling control of infant incubator[J]. Transducer and Microsystem Technologies,2021,40(7):156—160.

[11] ABHISHEK D, KUMAR P M, BHOLA J. Moth-flame optimization-based fuzzy-PID controller for optimal control of active magnetic bearing system[J]. Iranian Journal of Science and Technology, Transactions of Electrical Engineering,2018,42(4):451—463.

[12] KENNEDY J, EBERHART R. Particle swarm optimization[C]//Proc of IEEE Int Conf Neural Networks, Perth, Australia, 1995: 1942—1948.

[13] 张开生,折娇. 基于模糊理论的蒸汽加热罐温度控制系统的设计[J]. 传感器与微系统,2012,31(2):118—120. ZHANG Kaisheng, SHE Jiao. Design of temperature control system for steam heating can based on fuzzy theory[J]. Transducer and Microsystem Technologies,2012,31(2):118—120.

作者简介:
罗小燕(1967—),女,硕士,副教授,研究领域为计算机测控与智能技术,机电系统智能监测与控制。
吴庆龄(1997—),女,硕士研究生,研究方向为计算机测控与智能技术,机电系统智能监测与控制。

(上接第108页)

参考文献:

[1] 江勇,马琨,宋宇. 基于 AT89C51 的医院输液监控系统[J]. 医疗装备,2007(1):8—10.

[2] 杨艳丹. 智能医疗输液系统的无线远程监控设计[D]. 太原:太原理工大学,2013.

[3] 陈仁,霍振振,张丰,等. 智能无线输液监控系统设计[J]. 电子制作,2020(9):24—26,33.

[4] 刘玉忠,严荣国,赵伟兵,等. 基于无线蓝牙的静脉输液监控器的设计[J]. 电子测量技术,2019,42(21):21—26.

[5] 陆志颖,陈明霞,黎洪甫,等. 基于 STC89C52 的智能输液监控系统[J]. 中国科技信息,2019(1):64—66,13.

[6] 刘俊昕. 生物医学电容传感器接口电路芯片的研究与设计[D]. 桂林:桂林电子科技大学,2019.

[7] 柳科. 基于物联网芯片 ESP8266 的智能遥控车[J]. 中国新通信,2018,20(1):41.

[8] 王欣蕾,刘念. 基于 ESP8266 模块的数据采集与上传系统的设计与实现[J]. 科技风,2018,359(27):120.

[9] 张颖. 云计算环境下的数据安全问题与防护策略研究[J]. 电子世界,2020(1):93—94.

[10] 张锬,柯亚唯. 基于前后端分离技术的电厂信息管理系统后台程序开发[J]. 科技创新与应用,2018(2):156—157,161.

[11] 吴桦,王凌,程光. 基于 DASH 流媒体的 TCP 拥塞控制算法优化[J]. 计算机研究与发展,2019,56(9):1953—1964.

[12] 王鹤琴,张林静,朱珍元. 基于 Spring MVC 的后台管理系统开发研究[J]. 黄山学院学报,2018,20(3):18—22.

[13] 范开勇,陈宇收. MySQL 数据库性能优化研究[J]. 中国新通信,2019,21(1):57.

[14] 张中玉. 基于 DUBBO 和 SSM 的口腔门诊管理系统的设计与实现[D]. 杭州:浙江工业大学,2017.

作者简介:
王健(1994—),男,硕士研究生,研究方向为嵌入式开发。
陈晓宁(1977—),男,通讯作者,博士,副教授,硕士研究生导师,研究领域为电检测技术,智能仪器设备,环保仪器设备,系统软件开发等。